

Detección de Anomalías en Tráfico de Red mediante Máquinas de Vectores de Soporte Cuánticas: Validación Empírica en Hardware Cuántico de Resonancia Magnética Nuclear

Ticiane Angelucci
Licenciatura en Sistemas
Universidad Champagnat
Mendoza, Argentina

Rodrigo Elgueta
Director de Tesina
Universidad Champagnat
Mendoza, Argentina

Andrés A. Reynoso
Asesor Científico
Instituto Balseiro
Bariloche, Argentina

Resumen—Los Sistemas de Detección de Intrusos (IDS) basados en Machine Learning clásico enfrentan limitaciones crecientes ante el volumen y la complejidad del tráfico de red moderno. El Quantum Machine Learning (QML) ofrece un paradigma alternativo que proyecta los datos en espacios de características de alta dimensionalidad. Este trabajo presenta una Máquina de Vectores de Soporte Cuántica (QSVM) basada en un kernel cuántico de fidelidad para la clasificación binaria de tráfico de red (benigno frente a malicioso), empleando el dataset CIC-IDS-2017. Se documenta la transición desde un Clasificador Cuántico Variacional (VQC) —afectado por mesetas estériles (*barren plateaus*)— hacia el enfoque de kernel, más robusto para datos tabulares. El modelo QSVM alcanzó una exactitud del 83,33 % en simulación clásica (596 registros). La validación se trasladó a hardware cuántico real de Resonancia Magnética Nuclear (SpinQ Triangulum, 3 qubits), donde se realizaron dos experimentos: sobre datos CICIDS preprocesados se obtuvo una exactitud del 100 % con una desviación del kernel del 12,94 %; sobre tráfico capturado en vivo, la exactitud descendió al 50 % con una desviación del 41,71 %. Ambos experimentos utilizaron 4 muestras de entrenamiento y 4 de prueba (26 circuitos cuánticos, ≈ 1 hora de ejecución), lo que limita las conclusiones estadísticas pero constituye una prueba de viabilidad funcional y un insumo valioso para futuras campañas experimentales.

Palabras clave—Quantum Machine Learning, QSVM, kernel cuántico, detección de intrusos, era NISQ, resonancia magnética nuclear, CIC-IDS-2017, ciberseguridad.

I. INTRODUCCIÓN

La evolución y sofisticación de los ciberataques, sumada al crecimiento exponencial del tráfico en las infraestructuras de red, ha llevado a los Sistemas de Detección de Intrusos (IDS) clásicos a un punto de saturación. Los enfoques basados en firmas y, más recientemente, en Machine Learning (ML) clásico, alcanzan un techo de rendimiento y escalabilidad frente a la alta dimensionalidad de los datos de red modernos, lo que se traduce en tasas elevadas de falsos positivos y negativos.

El Quantum Machine Learning (QML) emerge como un cambio de paradigma prometedor [1]. Su ventaja teórica radica en la capacidad de mapear datos complejos en espacios de Hilbert de dimensionalidad exponencial, habilitando fronteras

de separación inaccesibles para los métodos clásicos. No obstante, la industria transita actualmente la era NISQ (*Noisy Intermediate-Scale Quantum*) [2], caracterizada por procesadores de escala intermedia con alta susceptibilidad al ruido, la decoherencia y los errores de compuerta.

Esta investigación se centra en una Máquina de Vectores de Soporte Cuántica (QSVM) que emplea un circuito cuántico para estimar un kernel de similitud entre muestras de tráfico de red, delegando la clasificación final en una SVM clásica. A diferencia de los circuitos variacionales puros, este enfoque evita los bucles de optimización cuántica iterativa y, con ello, el colapso por mesetas estériles.

Las principales contribuciones de este reporte de avance son:

- El diseño e implementación de una QSVM basada en un kernel cuántico de fidelidad para la clasificación binaria de tráfico de red, con un *pipeline* de preprocesamiento adaptado a un procesador de 3 qubits.
- El análisis comparativo que motivó la transición desde un Clasificador Cuántico Variacional (VQC) hacia el enfoque de kernel, documentando el fenómeno de mesetas estériles sobre datos tabulares.
- Resultados empíricos de ejecución en un procesador cuántico de Resonancia Magnética Nuclear (SpinQ Triangulum), contrastados con la simulación clásica ideal en dos escenarios: datos preprocesados del dataset CICIDS y tráfico capturado en vivo.

El resto del documento se organiza de la siguiente manera: la Sección II presenta el marco teórico; la Sección III detalla la metodología; la Sección IV describe la implementación; la Sección V expone los resultados experimentales; la Sección VI discute los hallazgos; y la Sección VII concluye y delinea el trabajo futuro.

II. MARCO TEÓRICO Y TRABAJOS RELACIONADOS

II-A. IDS y Machine Learning clásico

Históricamente, la detección de intrusos ha dependido de firmas conocidas o de anomalías estadísticas simples. La

literatura reciente documenta una transición hacia algoritmos de ML clásico (*Random Forest*, SVM, redes neuronales profundas), que mejoran la clasificación pero enfrentan barreras de escalabilidad. En este trabajo se adopta un modelo *Random Forest* como línea base (*baseline*) de referencia.

II-B. Quantum Machine Learning y kernels cuánticos

El QML explota la superposición y el entrelazamiento para procesar información [1]. Dentro de este campo, los métodos basados en kernels cuánticos resultan particularmente atractivos para la era NISQ: un circuito cuántico actúa como un mapa de características (*feature map*) que proyecta los datos clásicos en un espacio de Hilbert de alta dimensionalidad, y la similitud entre muestras se estima mediante una medida de fidelidad cuántica. La clasificación final recae en un modelo clásico (SVM), lo que confiere estabilidad al conjunto.

II-C. Clasificadores variacionales y mesetas estériles

Los Clasificadores Cuánticos Variacionales (VQC) son el análogo cuántico de una red neuronal: combinan un *feature map* con un circuito parametrizado (*ansatz*) cuyos pesos se optimizan iterativamente con un optimizador clásico (p. ej., COBYLA). Sin embargo, los VQC sufren de *barren plateaus*: a medida que crecen los qubits y la profundidad del circuito, los gradientes se aplanan exponencialmente hacia cero y el optimizador queda «ciego». Este fenómeno, sumado a la incompatibilidad de los datos tabulares de red con la geometría natural de los circuitos profundos, motivó la adopción del enfoque QSVM en este trabajo (Sección III-D).

II-D. Dataset CIC-IDS-2017

Se emplea el conjunto de datos público CIC-IDS-2017 [3], generado por el *Canadian Institute for Cybersecurity*. Contiene tráfico benigno y múltiples tipos de ataques (DDoS, *botnet*, fuerza bruta), con más de 70 características por conexión y etiquetado supervisado. Su uso garantiza validez científica y comparabilidad con el estado del arte.

II-E. Hardware cuántico de Resonancia Magnética Nuclear

La validación física se realiza sobre un procesador SpinQ Triangulum, una computadora cuántica de escritorio basada en Resonancia Magnética Nuclear (RMN) de 3 qubits. A diferencia de las arquitecturas superconductoras, la RMN opera mediante pulsos de radiofrecuencia sobre un conjunto macroscópico de moléculas y devuelve distribuciones de conteos por cada ejecución. Sus principales limitaciones son los tiempos de relajación (T_1) y de decoherencia (T_2), que degradan los estados cuánticos durante la ejecución del circuito.

III. METODOLOGÍA

La investigación adopta un enfoque cuantitativo y experimental, estructurado en el *pipeline* ilustrado en la Fig. 1.




Figura 1. Arquitectura general del *pipeline* QSVM. El núcleo cuántico puede ejecutarse sobre un simulador clásico o sobre hardware físico antes de la etapa de clasificación clásica.

III-A. Preprocesamiento de datos

El dataset original supera las 70 características, incompatibles con un procesador de 3 qubits. El preprocesamiento incluye: limpieza de valores nulos e infinitos, conversión de etiquetas a formato binario (benigno frente a ataque), y selección de las $k = 3$ características más discriminativas mediante *SelectKBest* con test estadístico ANOVA F (`f_classif`), que evalúa la significancia de cada característica respecto a la variable objetivo. Se descartó el PCA tradicional para el modelo cuántico por producir componentes de difícil interpretación física en espacios reducidos. Los valores se escalan al rango $[-1, 1]$ con un `MinMaxScaler` ajustado exclusivamente sobre el conjunto de entrenamiento, para evitar el fenómeno de *phase wrapping* en las compuertas de rotación del circuito y prevenir fuga de información (*data leakage*).

III-B. Arquitectura QSVM: feature map y kernel de fidelidad

La codificación se realiza mediante un `ZZFeatureMap` con entrelazamiento lineal. Para un vector de entrada $\mathbf{x}$, el estado cuántico se prepara como:

$$|\phi(\mathbf{x})\rangle = U_{\text{FM}}(\mathbf{x})|0\rangle^{\otimes n}, \quad (1)$$

donde U_{FM} aplica rotaciones Z dependientes de los datos y compuertas ZZ que entrelazan qubits adyacentes. El kernel cuántico de fidelidad entre dos muestras se define como:

$$K(\mathbf{x}_i, \mathbf{x}_j) = |\langle \phi(\mathbf{x}_i) | \phi(\mathbf{x}_j) \rangle|^2 = |\langle 0 | U_{\text{FM}}^\dagger(\mathbf{x}_j) U_{\text{FM}}(\mathbf{x}_i) | 0 \rangle|^2. \quad (2)$$

Esta matriz de similitudes alimenta una SVM clásica, que aprende la frontera de separación entre las clases. El entrelazamiento lineal (en lugar de completo) reduce el número de compuertas CNOT cruzadas, mitigando la decoherencia en hardware físico. En el simulador se emplea una profundidad de `reps=2`; en el procesador real se reduce a `reps=1` para minimizar el tiempo de exposición al ruido.

III-C. Decisión de diseño: del VQC al QSVM

El modelo inicial de esta investigación fue un VQC entrenado con COBYLA. Sin embargo, al escalar el volumen de datos y la profundidad del *ansatz*, el entrenamiento colapsó hacia métricas cercanas al azar, síntoma inequívoco de mesetas estériles. Los datos tabulares de ciberseguridad carecen de la

Cuadro I
CIRCUITOS DE FIDELIDAD REQUERIDOS POR TAMAÑO DE MUESTRA.

Muestras train	Muestras test	Circuitos cuánticos
4	4	26
6	4	45
8	4	68
8	8	100
10	10	155
20	10	420
20	20	610

estructura geométrica que los circuitos variacionales profundos mapean eficientemente.

La transición hacia el QSVM constituyó el punto de inflexión: al separar el cómputo cuántico (el kernel es estático y no requiere optimización iterativa) del entrenamiento clásico (SVM), se elimina el riesgo de colapso por gradientes planos. Esta decisión de diseño, documentada como lección aprendida, fue la que permitió alcanzar un rendimiento estable y reproducible.

III-D. Estrategia de validación en hardware

Dada la limitación de qubits y el costo computacional del kernel, la validación física se acota a subconjuntos reducidos de entrenamiento y prueba. El número de circuitos de fidelidad requeridos crece según la Tabla I. En el hardware SpinQ, la ejecución de 26 circuitos cuánticos (correspondientes a 4 muestras de entrenamiento y 4 de prueba) demanda aproximadamente 1 hora de tiempo de procesador, lo que restringe severamente el tamaño de las muestras evaluables en cada sesión.

IV. IMPLEMENTACIÓN

IV-A. Stack tecnológico

El prototipo se desarrolló en Python, empleando Qiskit y qiskit-machine-learning para el modelado cuántico [4]; scikit-learn, pandas y numpy para el preprocesamiento y el *baseline* clásico; y Streamlit para el *dashboard* de visualización. La simulación local se realizó con qiskit-aer.

IV-B. Generación de tráfico y detección en vivo

Para evaluar el modelo frente a ataques realistas se implementó un simulador de tráfico basado en Scapy, capaz de generar inundaciones TCP SYN, UDP e ICMP, así como ataques híbridos multivector y tráfico de fondo. Un módulo de detección en vivo captura paquetes, extrae características por ventanas temporales y las clasifica en tiempo real.

IV-C. Integración con hardware cuántico

La ejecución física se realiza sobre un procesador SpinQ Triangulum (RMN, 3 qubits). La conexión se gestiona mediante la librería *spinqit* sobre TCP/IP. A diferencia de los dispositivos superconductores, el hardware de RMN opera mediante pulsos de radiofrecuencia sobre un conjunto macroscópico de moléculas y devuelve distribuciones de conteos (*counts*) por cada ejecución, con 1024 disparos por circuito.




Figura 2. Esquema del circuito de fidelidad para 3 qubits. Compara dos registros de red midiendo la probabilidad de retornar al estado $|000\rangle$.

Cuadro II
CONFIGURACIÓN DEL MODELO QSVM.

Parámetro	Valor
Qubits	3
Feature Map	ZZFeatureMap (entrelazamiento lineal)
Profundidad (simulador)	reps= 2
Profundidad (hardware)	reps= 1
Selección de características	SelectKBest – ANOVA F ($k = 3$)
Escalado	MinMax $[-1, 1]$
Kernel	FidelityQuantumKernel
Clasificador	SVM clásica
Disparos (<i>shots</i>)	1024

Cuadro III
COMPARACIÓN DE MÉTRICAS POR MODELO Y ENTORNO (%).

Modelo / Entorno	Acc.	Prec.	Recall	F1
Random Forest (clásico)	99,76	91,21	84,91	87,95
QSVM simulador (3q, reps=2)	83,33	75,00	100,00	85,71
SpinQ – CICODES (3q)	100,00	97,00	100,00	97,00
SpinQ – Live (3q)	50,00	50,00	100,00	66,67

IV-D. Circuito de fidelidad

La Fig. 2 esquematiza el circuito empleado. Los tres qubits codifican las características seleccionadas; las compuertas de Hadamard preparan la superposición, las rotaciones R_z codifican los datos, y las compuertas CNOT introducen dependencias entre características. La fidelidad se estima a partir de la probabilidad de medir el estado $|000\rangle$:

$$\hat{F} \approx \frac{N_{000}}{N_{\text{shots}}}, \quad (3)$$

con $N_{\text{shots}} = 1024$. El circuito prepara el estado de la muestra A, aplica la operación inversa correspondiente a la muestra B, y mide la probabilidad de retornar al estado fundamental.

V. RESULTADOS EXPERIMENTALES

V-A. Configuración experimental

La Tabla II resume la configuración del modelo cuántico.

V-B. Resultados consolidados

La Tabla III presenta las métricas obtenidas en los cuatro experimentos evaluados: el *baseline* clásico, el QSVM en simulación, y dos validaciones independientes en hardware SpinQ.

V-C. Baseline clásico y QSVM en simulación

El modelo *Random Forest*, entrenado sobre el dataset completo preprocesado, alcanzó una exactitud del 99,76 %, confirmando la separabilidad de las clases en el espacio de características original.

El QSVM en simulación se evaluó sobre 596 registros válidos, divididos en 476 para entrenamiento y 120 para prueba. Se obtuvo una exactitud del 83,33 %, una precisión del 75 %, un recall del 100 % y un F1-Score del 85,71 %. El recall perfecto indica que el modelo detectó la totalidad de los ataques presentes en el conjunto de prueba, aunque a costa de una mayor tasa de falsos positivos (reflejada en la precisión del 75 %). La brecha respecto al baseline clásico es atribuible a la compresión extrema en 3 qubits y a la profundidad limitada del feature map.

V-D. Validación en hardware SpinQ: datos CICIDS

El primer experimento en hardware físico utilizó 4 muestras de entrenamiento y 4 de prueba extraídas del dataset CICIDS preprocesado, requiriendo la ejecución de 26 circuitos cuánticos de fidelidad (≈ 1 hora de tiempo de procesador). La matriz de confusión resultante fue:

$$\begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}, \quad (4)$$

clasificando correctamente las 4 muestras de prueba (2 benignas y 2 maliciosas), con una exactitud del 100 %, precisión del 97 %, recall del 100 % y F1-Score del 97 %.

El kernel físico presentó una desviación media del 12,94 % respecto del kernel ideal calculado en el simulador, con una desviación máxima del 47,95 %. Esta diferencia no fue suficiente para alterar la decisión final de la SVM en este caso particular.

V-E. Validación en hardware SpinQ: tráfico en vivo

El segundo experimento se realizó sobre tráfico capturado en vivo mediante el simulador de ataques basado en Scapy, utilizando la misma configuración de 4 muestras de entrenamiento y 4 de prueba (26 circuitos). En este escenario, la exactitud descendió al 50 %, con una precisión del 50 %, un recall del 100 % y un F1-Score del 66,67 %.

La desviación media del kernel respecto al simulador fue del 41,71 %, significativamente superior a la observada con datos CICIDS. El recall del 100 % indica que todos los ataques fueron detectados, pero la precisión del 50 % revela una tasa de falsos positivos equivalente a la de un clasificador aleatorio, sugiriendo que el ruido del hardware degradó la frontera de decisión para el tráfico benigno.

V-F. Caveat sobre el tamaño muestral

Es fundamental señalar que ambos experimentos en hardware se realizaron sobre un total de 4 muestras de prueba. Este tamaño es insuficiente para extraer conclusiones estadísticamente significativas sobre la capacidad de generalización del modelo. Los resultados constituyen una prueba de viabilidad

funcional del circuito en hardware real y un punto de partida para campañas experimentales futuras con muestras más representativas.

VI. DISCUSIÓN

VI-A. Robustez del enfoque de kernel

La transición del VQC al QSVM constituyó el hallazgo metodológico más relevante. Los datos tabulares de ciberseguridad carecen de la estructura geométrica que los circuitos variacionales profundos mapean eficientemente; el enfoque de kernel, en cambio, aprovecha la expresividad del espacio de Hilbert sin depender de bucles de optimización cuántica, evitando las mesetas estériles.

VI-B. Contraste entre CICIDS y tráfico en vivo

La marcada diferencia entre los resultados de hardware con datos CICIDS (exactitud 100 %) y tráfico en vivo (exactitud 50 %) admite varias interpretaciones complementarias:

- **Separabilidad de los datos:** el dataset CICIDS preprocesado presenta clases más claramente diferenciadas en el espacio de 3 características seleccionadas, mientras que el tráfico capturado en vivo introduce variabilidad estocástica, solapamiento de puertos y ruido temporal que difuminan la frontera de decisión.
- **Sensibilidad al ruido:** la desviación del kernel fue tres veces mayor en el experimento en vivo (41,71 % frente a 12,94 %), lo que sugiere que las muestras de tráfico real son más susceptibles a la decoherencia y las imperfecciones de los pulsos de radiofrecuencia.
- **Tamaño muestral:** con solo 4 muestras de prueba, cualquier métrica individual tiene una varianza extremadamente alta. Un único falso positivo ya reduce la exactitud al 75 %; dos, al 50 %.

VI-C. Limitaciones

Las principales limitaciones son: (i) la compresión a 3 qubits, que descarta información discriminativa; (ii) el tamaño extremadamente reducido de las muestras de prueba en hardware (4 registros), insuficiente para inferencias estadísticas robustas; (iii) el costo temporal de ejecución en hardware (≈ 1 hora por 26 circuitos), que restringe la cantidad de experimentos realizables por sesión; y (iv) el costo cuadrático del cálculo del kernel respecto al número de muestras.

VII. CONCLUSIONES Y TRABAJO FUTURO

Este trabajo demuestra la viabilidad funcional de un clasificador QSVM para la detección de anomalías en tráfico de red, tanto en simulación como en hardware cuántico real de RMN. El QSVM superó al VQC en estabilidad y precisión, y el hardware físico produjo clasificaciones correctas sobre datos preprocesados, aunque con rendimiento degradado sobre tráfico en vivo.

Los resultados en hardware, si bien prometedores en el caso CICIDS, deben interpretarse estrictamente como pruebas de viabilidad debido al tamaño muestral reducido (4 muestras

de prueba). No constituyen una estimación concluyente de la capacidad de generalización del modelo.

Como trabajo futuro se prevé: (i) ampliar significativamente el tamaño de las muestras de validación física, aprovechando el acceso continuado al hardware SpinQ; (ii) explorar embeddings con entrelazamiento dependiente de los datos para enriquecer el kernel; (iii) aplicar técnicas de mitigación de errores (extrapolación a ruido cero); (iv) extender la comparación a plataformas superconductoras y de iones atrapados vía IBM Quantum y Amazon Braket; y (v) consolidar el *dashboard* interactivo como herramienta de referencia para la comunidad.

REFERENCIAS

- [1] J. Biamonte, P. Wittek, N. Pancotti, P. Rebentrost, N. Wiebe y S. Lloyd, “Quantum machine learning,” *Nature*, vol. 549, n.º 7671, pp. 195–202, 2017.
- [2] J. Preskill, “Quantum Computing in the NISQ era and beyond,” *Quantum*, vol. 2, p. 79, 2018.
- [3] I. Sharafaldin, A. H. Lashkari y A. Ghorbani, “Toward generating a new intrusion detection dataset and intrusion traffic characterization,” en *Proc. ICISSP*, 2018, pp. 108–116.
- [4] Qiskit contributors, “Qiskit: An open-source framework for quantum computing,” IBM Quantum, 2023.
- [5] IBM Quantum, “IBM Quantum Learning.” [En línea]. Disponible: <https://learning.quantum.ibm.com/>.