

Detección de Anomalías en Tráfico de Red mediante Máquinas de Vectores de Soporte Cuánticas: Validación Empírica en Hardware Cuántico de Resonancia Magnética Nuclear

Ticiane Angelucci
Licenciatura en Sistemas
Universidad Champagnat
Mendoza, Argentina

Rodrigo Elgueta
Director de Tesina
Universidad Champagnat
Mendoza, Argentina

Andrés A. Reynoso
Asesor Científico
Instituto Balseiro
Bariloche, Argentina

Resumen—Los Sistemas de Detección de Intrusos (IDS) basados en Machine Learning clásico enfrentan limitaciones crecientes ante el volumen y la complejidad del tráfico de red moderno. El Quantum Machine Learning (QML) ofrece un paradigma alternativo que proyecta los datos en espacios de características de alta dimensionalidad (espacios de Hilbert). Este trabajo presenta una Máquina de Vectores de Soporte Cuántica (QSVM) basada en un kernel cuántico de fidelidad para la clasificación binaria de tráfico de red benigno y malicioso, empleando el dataset CIC-IDS-2017. Se documenta la decisión de diseño de abandonar un Clasificador Cuántico Variacional (VQC) —afectado por el problema de mesetas estériles (barren plateaus)— en favor del enfoque de kernel, más robusto para datos tabulares de ciberseguridad. El modelo QSVM alcanzó una exactitud del 83,3 % en simulación clásica. La validación se trasladó a hardware cuántico real de Resonancia Magnética Nuclear (SpinQ Triangulum, 3 qubits), donde una prueba sobre tráfico en vivo arrojó una exactitud del 75 %, una precisión del 100 % y un F1-Score del 80 %, con una desviación media del kernel del 12,94 % respecto del valor ideal. Los resultados evidencian tanto la viabilidad funcional del enfoque como el impacto del ruido inherente a la era NISQ.

Palabras clave—Quantum Machine Learning, QSVM, kernel cuántico, detección de intrusos, era NISQ, resonancia magnética nuclear, CIC-IDS-2017, ciberseguridad.

I. Introducción

La evolución y sofisticación de los ciberataques, sumada al crecimiento exponencial del tráfico en las infraestructuras de red, ha llevado a los Sistemas de Detección de Intrusos (IDS) clásicos a un punto de saturación. Los enfoques basados en firmas y, más recientemente, en Machine Learning (ML) clásico, alcanzan un techo de rendimiento y escalabilidad frente a la alta dimensionalidad de los datos de red modernos, lo que se traduce en tasas elevadas de falsos positivos y negativos.

El Quantum Machine Learning (QML) emerge como un cambio de paradigma prometedor [1]. Su ventaja teórica radica en la capacidad de mapear datos complejos en espacios de Hilbert de dimensionalidad exponencial, habilitando fronteras de separación inaccesibles para los

métodos clásicos. No obstante, la industria transita actualmente la era NISQ (Noisy Intermediate-Scale Quantum) [2], caracterizada por procesadores de escala intermedia con alta susceptibilidad al ruido, la decoherencia y los errores de compuerta.

Esta investigación se centra en una Máquina de Vectores de Soporte Cuántica (QSVM) que emplea un circuito cuántico para estimar un kernel de similitud entre muestras de tráfico de red, delegando la clasificación final en una SVM clásica. A diferencia de los circuitos variacionales puros, este enfoque evita los bucles de optimización cuántica iterativa y, con ello, el colapso por mesetas estériles.

Las principales contribuciones de este reporte de avance son:

- El diseño e implementación de una QSVM basada en un kernel cuántico de fidelidad para la clasificación binaria de tráfico de red, con un pipeline de preprocesamiento adaptado a un procesador de 3 qubits.
- El análisis comparativo que motivó la transición desde un Clasificador Cuántico Variacional (VQC) hacia el enfoque de kernel, documentando el fenómeno de mesetas estériles sobre datos tabulares.
- Resultados empíricos de ejecución en un procesador cuántico de Resonancia Magnética Nuclear (SpinQ Triangulum), contrastados con la simulación clásica ideal.

El resto del documento se organiza de la siguiente manera: la Sección II presenta el marco teórico; la Sección III detalla la metodología; la Sección IV describe la implementación; la Sección V expone los resultados experimentales; la Sección VI discute los hallazgos; y la Sección VII concluye y delinea el trabajo futuro.

II. Marco Teórico y Trabajos Relacionados

II-A. IDS y Machine Learning clásico

Históricamente, la detección de intrusos ha dependido de firmas conocidas o de anomalías estadísticas simples.

La literatura reciente documenta una transición hacia algoritmos de ML clásico (Random Forest, SVM, redes neuronales profundas), que mejoran la clasificación pero enfrentan barreras de escalabilidad. En este trabajo se adopta un modelo Random Forest como línea base (baseline) de referencia.

II-B. Quantum Machine Learning y kernels cuánticos

El QML explota la superposición y el entrelazamiento para procesar información [1]. Dentro de este campo, los métodos basados en kernels cuánticos resultan particularmente atractivos para la era NISQ: un circuito cuántico actúa como un mapa de características (feature map) que proyecta los datos clásicos en un espacio de Hilbert de alta dimensionalidad, y la similitud entre muestras se estimación mediante una medida de fidelidad cuántica. La clasificación final recae en un modelo clásico (SVM), lo que confiere estabilidad al conjunto.

II-C. Clasificadores variacionales y mesetas estériles

Los Clasificadores Cuánticos Variacionales (VQC) son el análogo cuántico de una red neuronal: combinan un feature map con un circuito parametrizado (ansatz) cuyos pesos se optimizan iterativamente con un optimizador clásico (p. ej., COBYLA). Sin embargo, los VQC sufren de barren plateaus: a medida que crecen los qubits y la profundidad del circuito, los gradientes se aplanan exponencialmente hacia cero y el optimizador queda «ciego». Este fenómeno, sumado a la incompatibilidad de los datos tabulares de red con la geometría natural de los circuitos profundos, motivó la adopción del enfoque QSVM en este trabajo (Sección III-D).

II-D. Dataset CIC-IDS-2017

Se emplea el conjunto de datos público CIC-IDS-2017 [3], generado por el Canadian Institute for Cybersecurity. Contiene tráfico benigno y múltiples tipos de ataques (DDoS, botnet, fuerza bruta), con más de 70 características por conexión y etiquetado supervisado. Su uso garantiza validez científica y comparabilidad con el estado del arte.

II-E. Hardware cuántico de Resonancia Magnética Nuclear

La validación física se realiza sobre un procesador SpinQ Triangulum, una computadora cuántica de escritorio basada en Resonancia Magnética Nuclear (RMN) de 3 qubits. A diferencia de las arquitecturas superconductoras, la RMN opera mediante pulsos de radiofrecuencia sobre un conjunto macroscópico de moléculas y devuelve distribuciones de conteos por cada ejecución. Sus principales limitaciones son los tiempos de relajación (T_1) y de decoherencia (T_2), que degradan los estados cuánticos durante la ejecución del circuito.




Figura 1. Arquitectura general del pipeline QSVM. El núcleo cuántico puede ejecutarse sobre un simulador clásico o sobre hardware físico antes de la etapa de clasificación clásica.

III. Metodología

La investigación adopta un enfoque cuantitativo y experimental, estructurado en el pipeline ilustrado en la Fig. 1.

III-A. Preprocesamiento de datos

El dataset original supera las 70 características, incompatibles con un procesador de 3 qubits. El preprocesamiento incluye: limpieza de valores nulos e infinitos, conversión de etiquetas a formato binario (benigno frente a ataque), y selección de las $k = 3$ características más discriminativas mediante SelectKBest (test de información mutua). Se descartó el PCA tradicional para el modelo cuántico por producir componentes de difícil interpretación física en espacios reducidos. Los valores se escalan al rango $[-1, 1]$ con un MinMaxScaler ajustado, para evitar el fenómeno de phase wrapping en las compuertas de rotación del circuito.

III-B. Arquitectura QSVM: feature map y kernel de fidelidad

La codificación se realiza mediante un ZZFeatureMap con entrelazamiento lineal. Para un vector de entrada $\mathbf{x}$, el estado cuántico se prepara como:

$$|\phi(\mathbf{x})\rangle = U_{\text{FM}}(\mathbf{x})|0\rangle^{\otimes n}, \quad (1)$$

donde U_{FM} aplica rotaciones Z dependientes de los datos y compuertas ZZ que entrelazan qubits adyacentes. El kernel cuántico de fidelidad entre dos muestras se define como:

$$K(\mathbf{x}_i, \mathbf{x}_j) = |\langle \phi(\mathbf{x}_i) | \phi(\mathbf{x}_j) \rangle|^2 = |\langle 0 | U_{\text{FM}}^\dagger(\mathbf{x}_j) U_{\text{FM}}(\mathbf{x}_i) | 0 \rangle|^2. \quad (2)$$

Esta matriz de similitudes alimenta una SVM clásica, que aprende la frontera de separación entre las clases. El entrelazamiento lineal (en lugar de completo) reduce el número de compuertas CNOT cruzadas, mitigando la decoherencia en hardware físico; en el procesador real se emplea una profundidad de reps= 1 para minimizar el tiempo de exposición al ruido.

Cuadro I
Circuitos de fidelidad requeridos por tamaño de muestra.

Muestras train	Muestras test	Circuitos cuánticos
4	4	26
6	4	45
8	4	68
8	8	100
10	10	155

III-C. Decisión de diseño: del VQC al QSVM

El modelo inicial de esta investigación fue un VQC entrenado con COBYLA. Sin embargo, al escalar el volumen de datos y la profundidad del ansatz, el entrenamiento colapsó hacia métricas cercanas al azar, síntoma inequívoco de mesetas estériles. Los datos tabulares de ciberseguridad carecen de la estructura geométrica que los circuitos variacionales profundos mapean eficientemente.

La transición hacia el QSVM constituyó el punto de inflexión: al separar el cómputo cuántico (el kernel es estático y no requiere optimización iterativa) del entrenamiento clásico (SVM), se elimina el riesgo de colapso por gradientes planos. Esta decisión de diseño, documentada como lección aprendida, fue la que permitió alcanzar un rendimiento estable y reproducible.

III-D. Estrategia de validación en hardware

Dada la limitación de qubits y el costo computacional del kernel, la validación física se acota a subconjuntos reducidos de entrenamiento y prueba. El número de circuitos de fidelidad requeridos crece según la Tabla I.

IV. Implementación

IV-A. Stack tecnológico

El prototipo se desarrolló en Python, empleando Qiskit y qiskit-machine-learning para el modelado cuántico [4]; scikit-learn, pandas y numpy para el preprocesamiento y el baseline clásico; y Streamlit para el dashboard de visualización. La simulación local se realizó con qiskit-aer.

IV-B. Generación de tráfico y detección en vivo

Para evaluar el modelo frente a ataques realistas se implementó un simulador de tráfico basado en Scapy, capaz de generar inundaciones TCP SYN, UDP e ICMP, así como ataques híbridos multivector y tráfico de fondo. Un módulo de detección en vivo captura paquetes, extrae características por ventanas temporales y las clasifica en tiempo real.

IV-C. Integración con hardware cuántico

La ejecución física se realiza sobre un procesador SpinQ Triangulum (RMN, 3 qubits). La conexión se gestiona mediante la librería spinqit sobre TCP/IP. A diferencia de los dispositivos superconductores, el hardware de RMN opera mediante pulsos de radiofrecuencia sobre un conjunto macroscópico de moléculas y devuelve distribuciones de




Figura 2. Esquema del circuito de fidelidad para 3 qubits. Compara dos registros de red midiendo la probabilidad de retornar al estado $|000\rangle$.

Cuadro II
Configuración del modelo QSVM.

Parámetro	Valor
Qubits	3
Feature Map	ZZFeatureMap (entrelazamiento lineal)
Profundidad (hardware)	reps= 1
Selección de características	SelectKBest ($k = 3$)
Escalado	MinMax $[-1, 1]$
Kernel	FidelityQuantumKernel
Clasificador	SVM clásica
Disparos (shots)	1024

conteos (counts) por cada ejecución, con 1024 disparos por circuito.

IV-D. Circuito de fidelidad

La Fig. 2 esquematiza el circuito empleado. Los tres qubits codifican las características seleccionadas; las compuertas de Hadamard preparan la superposición, las rotaciones R_z codifican los datos, y las compuertas CNOT introducen dependencias entre características. La fidelidad se estima a partir de la probabilidad de medir el estado $|000\rangle$:

$$\hat{F} \approx \frac{N_{000}}{N_{\text{shots}}}, \quad (3)$$

con $N_{\text{shots}} = 1024$. El circuito prepara el estado de la muestra A, aplica la operación inversa correspondiente a la muestra B, y mide la probabilidad de retornar al estado fundamental.

V. Resultados Experimentales

V-A. Configuración experimental

La Tabla II resume la configuración del modelo cuántico.

V-B. Baseline clásico y QSVM en simulación

La Tabla III consolida las métricas obtenidas en los distintos entornos evaluados.

El modelo QSVM en simulación alcanzó una exactitud del 83,3 %, un resultado significativamente superior al del VQC, que no logró convergencia estable sobre los mismos datos. Este contraste constituye la principal evidencia empírica que justificó la transición de arquitectura.

Cuadro III
Comparación de métricas por entorno (%).

Modelo / Entorno	Acc.	Prec.	Recall	F1
Random Forest (clásico)	[completar]	[completar]	[completar]	[completar]
QSVM (simulador)	83,3	[completar]	[completar]	[completar]
QSVM (SpinQ, laboratorio)	25,0	33,3	50,0	40,0
QSVM (SpinQ, en vivo)	75,0	100,0	66,7	80,0

V-C. QSVM en hardware cuántico real

La primera ejecución en el laboratorio (dataset estático) arrojó métricas cercanas al azar (25 % de exactitud), atribuibles a la compresión extrema en 3 qubits, la decoherencia y una decodificación heurística simplificada.

Tras refinar la selección de características, el embedding y el criterio de decodificación, la validación sobre tráfico en vivo alcanzó una exactitud del 75 %, con una precisión del 100 % (ausencia total de falsos positivos) y un F1-Score del 80 %. En una validación acotada final (4 muestras de entrenamiento y 4 de prueba) el QSVM clasificó correctamente los 8 registros, obteniendo una matriz de confusión con 2 verdaderos positivos y 2 verdaderos negativos; no obstante, el kernel físico presentó una desviación media del 12,94 % (desviación máxima del 47,95 %) respecto del kernel ideal del simulador.

VI. Discusión

VI-A. Robustez del enfoque de kernel

La transición del VQC al QSVM constituyó el hallazgo metodológico más relevante. Los datos tabulares de ciberseguridad carecen de la estructura geométrica que los circuitos variacionales profundos mapean eficientemente; el enfoque de kernel, en cambio, aprovecha la expresividad del espacio de Hilbert sin depender de bucles de optimización cuántica, evitando las mesetas estériles. Esta lección es transferible a otros problemas de clasificación tabular en la era NISQ.

VI-B. Impacto del ruido NISQ

El ruido de decoherencia (T_1 , T_2) y las imperfecciones de los pulsos de radiofrecuencia introducen estados espurios en las mediciones (p. ej., los conteos $|01\rangle$ y $|10\rangle$ en un estado de Bell). Curiosamente, en el experimento en vivo el hardware superó a la primera prueba de laboratorio, fenómeno atribuible a una mayor separabilidad de las clases en las ventanas de tráfico atacado y, posiblemente, a un efecto de regularización por ruido. Este resultado, si bien prometedor, debe interpretarse con cautela dado el tamaño muestral reducido.

VI-C. Limitaciones

Las principales limitaciones son: (i) la compresión a 3 qubits, que descarta información discriminativa; (ii) el tamaño acotado de las muestras de prueba en hardware;

y (iii) el costo cuadrático del cálculo del kernel. Estos factores impiden, por el momento, generalizar los resultados a escala industrial.

VII. Conclusiones y Trabajo Futuro

Este trabajo demuestra la viabilidad funcional de un clasificador QSVM para la detección de anomalías en tráfico de red, tanto en simulación como en hardware cuántico real de RMN. El QSVM superó al VQC en estabilidad y precisión, y el hardware físico produjo clasificaciones significativamente superiores al azar pese al ruido inherente.

Como trabajo futuro se prevé: (i) ampliar el tamaño de las muestras de validación física; (ii) explorar embeddings con entrelazamiento dependiente de los datos para enriquecer el kernel; (iii) aplicar técnicas de mitigación de errores (extrapolación a ruido cero); (iv) extender la comparación a plataformas superconductoras y de iones atrapados vía IBM Quantum y Amazon Braket; y (v) consolidar el dashboard interactivo como herramienta de referencia.

Referencias

- [1] J. Biamonte, P. Wittek, N. Pancotti, P. Rebentrost, N. Wiebe y S. Lloyd, “Quantum machine learning,” *Nature*, vol. 549, n.º 7671, pp. 195–202, 2017.
- [2] J. Preskill, “Quantum Computing in the NISQ era and beyond,” *Quantum*, vol. 2, p. 79, 2018.
- [3] I. Sharafaldin, A. H. Lashkari y A. Ghorbani, “Toward generating a new intrusion detection dataset and intrusion traffic characterization,” en *Proc. ICISSP*, 2018, pp. 108–116.
- [4] Qiskit contributors, “Qiskit: An open-source framework for quantum computing,” IBM Quantum, 2023.
- [5] IBM Quantum, “IBM Quantum Learning.” [En línea]. Disponible: <https://learning.quantum.ibm.com/>.